

混合高斯分布的探究

在概率论中，如果我们有一个包含多个随机变量的随机变量集合，并基于该集合生成一个新的随机变量，则该随机变量的分布称为混合分布。混合高斯分布正是基于多个正态分布生成的一种混合分布。下面我们将对其进行探究。

1 探究任务一

1.1 混合高斯分布定义

随机变量 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$ ，则 $Z = X + \eta Y$ 服从的分布称为混合高斯分布。其中 $P(\eta = 0) = 1 - p$, $P(\eta = 1) = p$ 。

1.2 不同参数下的混合高斯分布频率直方图及参数对混合高斯分布“峰”的影响

混合高斯分布的参数有 $\mu_1, \sigma_1^2, \mu_2, \sigma_2^2, p$ 共五个。通过相应的 python 代码（见附录 B），我设定不同的参数值画出了以下频率分布直方图，相应的参数已经标注在图上。同时，为了使研究参数对混合高斯分布“峰”的影响更加便利，首先将随机变量 X 固定为标准正态分布的形式。

我们先画出一个比较的基准混合高斯分布频率直方图。可以发现，峰一般形成在两分布各自的均值处（即 μ_1, μ_2 处），因为在该处的值出现频率相较于其他值更高些。我们把由随机变量 X 产生的峰称为主峰，把由随机变量 Y 产生的峰称为次峰。




图 1: 混合高斯分布 ($\mu_1 = 0, \sigma_1^2 = 1, \mu_2 = 4, \sigma_2^2 = 1, p = 0.5$)

1.2.1 μ_2 对“峰”的影响




图 2: $\mu_2 = 4$




图 3: $\mu_2 = -4$

图 4: 对称的 μ_2 对“峰”的影响

当 μ_2 关于 μ_1 对称时，我们发现其直方图所呈现的峰也相互对称。
现在我们从 0 开始，逐渐增大 μ_2 的值，可以得到下面的一组图片。




图 5: 逐渐增大的 μ_2 对“峰”的影响

可以看到，当 μ_2 与 μ_1 较为接近时，直方图只显示出一个明显的主峰。当 μ_2 逐渐增大并偏离 μ_1 的过程中，主峰固定不动，次峰逐渐出现，且在 μ_2 越大时越为明显，移动距离也与 μ_2 的改变量相一致。同时，在 μ_2 增大的过程中，两峰之间的部分逐渐扩大，且相较于峰越来越低。

1.2.2 σ_2^2 对“峰”的影响

改变 σ_2^2 的值得到以下一组图片。




图 6: 逐渐增大的 σ_2^2 对“峰”的影响 1




图 7: 逐渐增大的 σ_2^2 对“峰”的影响

通过对上面图片的观察，不难发现， σ_2^2 影响的是次峰的高度及其周边的陡峭程度。当 σ_2^2 逐渐增大时，可以发现主峰未受影响，而次峰逐渐变矮，次峰周边地形逐渐趋于平坦，直到 σ_2^2 大到一定程度以至于无法观察到次峰的存在，比如图 7 (c) 的情况。

1.2.3 p 对“峰”的影响

改变 p 值得到以下一组图片。




图 8: 逐渐增大的 p 值对“峰”的影响

通过对上面图片的观察，不难发现， p 影响更多的是两个峰的相对高度。当 $p = 0$ 时， Z 的分布等同于 X 。当 $p = 1$ 时， Z 的分布等同于 $X + Y$ ，为两

个相互独立的正态分布相加，仍然为正态分布。而当 p 值介于 $(0, 1)$ 之间时， Y 代表的次峰逐渐变高，并逐渐超过 X 代表的主峰。根据图像大致可得到当 p 处于 $(0.5, 0.6)$ 之间时两个峰在某一 p 值达到等高水平（仅限于这里的特殊例子，并不一定普适）。

1.2.4 μ_1 对“峰”的影响

固定 $\mu_2 = 4$ ，改变 μ_1 得到以下一组图片。




图 9: 逐渐增大的 μ_1 对“峰”的影响

通过观察图片可以发现， μ_1 与 μ_2 的影响具有很大的差别。对于 μ_2 ，其主要影响着两峰之间部分的高度和宽度。但对于 μ_1 来说，两峰之间部分的高度和宽度基本没有太大的变化。 μ_1 增大产生的影响更像是将整张直方图向右进行了平移，平移量正是 μ_1 的改变量。两峰的相对高度和间距并未发生较大的变化。

1.2.5 σ_1^2 对“峰”的影响

固定 $\sigma_2^2 = 1$ ，改变 σ_1^2 得到以下一组图片。




图 10: 逐渐增大的 σ_1^2 对“峰”的影响

对于 σ_1^2 ，正如 σ_2^2 影响着次峰的高度与周边的陡峭程度， σ_1^2 影响着主峰的高度与周边的陡峭程度。当 σ_1^2 逐渐增大时，可以发现次主峰逐渐变矮，周边地形逐渐趋于平坦，直到 σ_1^2 大到一定程度以至于已经无法观察到主峰的存在，比如图 10 (d) (e) (f) 的情况。值得一提的是， σ_1^2 的变动对于陡峭程度的影响较 σ_2^2 的变动更为剧烈。

1.3 从密度函数角度分析上述结论

下面我从随机变量 Z 的密度函数出发，分析一下各个变量为什么会对“峰”产生上述图片展示的影响。

由 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, $\eta \sim B(1, p)$, $Z = X + \eta Y$, X, Y, η 相互独立:

$$X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

进一步计算 Z 的分布函数：

$$\begin{aligned} & F_z(Z) \\ &= P(Z \leq z) \\ &= P(X + \eta Y \leq z) \\ &= P(X \leq z | \eta = 0) P(\eta = 0) + P(X + Y \leq z | \eta = 1) P(\eta = 1) \\ &= P(X \leq z) P(\eta = 0) + P(X + Y \leq z) P(\eta = 1) \\ &= (1 - p) \int_{-\infty}^z \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}} dx + p \int_{-\infty}^z \frac{1}{\sqrt{2\pi}\sqrt{\sigma_1^2 + \sigma_2^2}} e^{-\frac{(x-\mu_1-\mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}} dx \end{aligned}$$

对分布函数求导得到密度函数：

$$f_Z(z) = (1 - p) \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(z-\mu_1)^2}{2\sigma_1^2}} + p \frac{1}{\sqrt{2\pi}\sqrt{\sigma_1^2 + \sigma_2^2}} e^{-\frac{(z-\mu_1-\mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}}$$

由密度函数，不难得出以下结论：

1. μ_2 的增大使两个峰的间距增大， μ_1 的变化使两个峰平移相同的距离。
2. σ_1^2 , σ_2^2 的变化使峰的形状变化，增大时使峰变矮。
3. p 改变了两项的权重，因而使两峰的相对高度发生了变化。当 p 增大时，次峰相对于主峰变高。

可以发现，上述结论与前面的图像得出的结论具有一致性。

2 探究任务二

2.1 混合高斯分布的期望与方差

由于 X, Y, η 相互独立, 可得下面的计算结论:

1. 计算期望 $E(Z)$:

$$\begin{aligned} E(Z) &= E(X + \eta Y) \\ &= E(X) + E(\eta)E(Y) \\ &= \mu_1 + p\mu_2 \end{aligned}$$

2. 计算方差 $D(Z)$:

$$\begin{aligned} D(Z) &= D(X + \eta Y) \\ &= D(X) + D(\eta Y) \end{aligned}$$

又

$$\begin{aligned} D(\eta Y) &= E(\eta^2 Y^2) - E^2(\eta Y) \\ &= E(\eta^2)E(Y^2) - (E(\eta)E(Y))^2 \\ &= (E^2(\eta) + D(\eta))(E^2(Y) + D(Y)) - (E(\eta)E(Y))^2 \\ &= E^2(\eta)D(Y) + E^2(Y)D(\eta) + D(\eta)D(Y) \\ &= p^2\sigma_2^2 + \mu_2^2p(1-p) + p(1-p)\sigma_2^2 \\ &= p\sigma_2^2 + \mu_2^2p(1-p) \end{aligned}$$

从而

$$D(Z) = \sigma_1^2 + p\sigma_2^2 + \mu_2^2p(1-p)$$

2.2 随机变量 U 的频率分布直方图及 n 值对峰的影响

2.2.1 随机变量 U 的形式

$$U_i = \frac{1}{\sqrt{nD(Z)}} \left(\sum_{j=1}^n Z_{ij} - nE(Z) \right)$$

其中, Z_{ij} 表示计算机生成的第 i 组第 j 个混合高斯分布随机数。总共生成 m 组每组 n 个的混合高斯分布随机数。这里我取 $m = 10000$ 。

2.2.2 n 值对峰的影响

为探究 n 值对峰的影响, 下面我固定 $\sigma_1^2 = 1$, $\sigma_2^2 = 1$, 修改 μ_1 , μ_2 的大小, 并改变 n 的值, 得到以下几组图片 (代码见附录 B)。

1. $\mu_1 = -4$, $\mu_2 = 4$ 。




图 11: $\mu_1 = -4$, $\mu_2 = 4$ 时改变 n 值对“峰”的影响

2. $\mu_1 = -8, \mu_2 = 8$ 。




图 12: $\mu_1 = -8, \mu_2 = 8$ 时改变 n 值对“峰”的影响

3. $\mu_1 = -16, \mu_2 = 16$ 。




图 13: $\mu_1 = -16, \mu_2 = 16$ 时改变 n 值对“峰”的影响 1




图 14: $\mu_1 = -16$, $\mu_2 = 16$ 时改变 n 值对“峰”的影响 2

4. $\mu_1 = -10000$, $\mu_2 = 10000$ 。




图 15: $\mu_1 = -10000$, $\mu_2 = 10000$ 时改变 n 值对“峰”的影响 1




图 16: $\mu_1 = -10000$, $\mu_2 = 10000$ 时改变 n 值对“峰”的影响 2

由以上四组图片，我们可以得出以下结论：

1. 当 μ_1 与 μ_2 较为接近时（如 $\mu_1 = -4$, $\mu_2 = 4$ ）， n 增大时始终没有很明显的双峰出现，唯一的峰位置在 $\mu_1 + \mu_2$ 处，整体始终接近于正态分布。
2. 当 μ_1 与 μ_2 有一定距离时（如 $\mu_1 = -8$, $\mu_2 = 8$; $\mu_1 = -8$, $\mu_2 = 8$ ），在 n 较小时（ $n = 2, 3, 4, 5$ ），出现峰的数目为 $n + 1$ ，但当 n 继续变大时，可辨别的峰数目呈现降低趋势，图像形状逐渐接近正态分布。这可能时因为峰的数目过多导致在分布的区间范围有限时，峰密度过大且较为低平，形成了许多峰连绵而变为正态分布的感觉。
3. 当 μ_1 与 μ_2 距离非常大时， n 较小时（ $n = 2, 3, 4, 5$ ），峰的数目仍然符合 2 所述的结论。 n 稍大一些时（ $n = 10, 20, 50$ ），仍然存在一些可辨别的峰。 n 极大时（ $n = 1000, 5000$ ），图像形状又接近于正态分布。
4. n 值对峰的分布无明显影响。峰的对称分布主要是 p 取值为 0.5 的缘故。当 p 值不是 0.5 时就不一定对称了。

2.3 对上述结论的理论分析

对于第 i 组，随机变量 $Z_{ij}, j = 1, 2, \dots, n$ 相互独立同分布， $E(Z_{ij}) = E(Z) = \mu_1 + p\mu_2$, $D(Z_{ij}) = D(Z) = \sigma_1^2 + p\sigma_2^2 + \mu_2^2 p(1 - p) < +\infty$ 。

由独立同分布的中心极限定理，我们可知：

$$\lim_{n \rightarrow +\infty} P\left(\frac{1}{\sqrt{nD(Z)}} \sum_{j=1}^n (Z_{ij} - E(Z)) \leq x\right) = \Phi(x)$$

$$\text{又 } U_i = \frac{1}{\sqrt{nD(Z)}}(\sum_{j=1}^n Z_{ij} - nE(Z)),$$

$$\lim_{n \rightarrow +\infty} P(U_i \leq x) = \Phi(x)$$

这也就是说，当 n 越来越大时， U 越来越接近于标准正态分布。这与上面的结论是一致的。

以上是本次探究混合高斯分布的大作业的全部内容。

3 感想

不仅是大作业的感想，也是我对概率论这门课的感想。

学期初的时候，或许是由于上学期学了概统的原因，我总觉得概率论这门课就是概统前一半的简单复刻，因此有点丧失了对这门课的热情。但渐渐地我发现不是这样，我发现概率论的世界里有那么多概统还没讲到的深处的好玩的点，发现概率论里也有独属于自己的各种收敛性，发现概率论在我们的生活里居然有这么大的用处。我体悟到概率论是一门很深的学问，它的价值不仅仅在于各种学科里的丰富应用，更在于其本身对这个世界不确定性曼妙的体系化阐释。

这次大作业我做的挺认真的，一方面当然是为了一个更好的分数，另一方面也是我想表达对这门课的认同与产生的共鸣。在写大作业的过程中，我感觉到自己的许多能力在被运用，在不断提高。python 的编写代码， $\text{\LaTeX}$ 的写作，课本知识的综合运用，网上资料的阅读思索。做完大作业后我对正态分布这一世界最重要的分布有了更深入的理解，对概率论中的公式、定理、分布等等有了更加具象化的体悟。

最后我想感谢熊老师能给我们这样一个机会去拓宽对概率论的眼界，也感谢熊老师一学期的辛勤付出和教学，感谢助教一学期的辛勤批改和答疑。希望这种有趣的大作业能得到传承。谢谢！

4 附录

A 混合高斯分布频率直方图生成代码

```
1  import numpy as np
2  import matplotlib.pyplot as plt
3  import seaborn as sns
4
5  #定义两个正态分布的参数
6  mu_1, sigma_1 = 0, 1
7  mu_2, sigma_2 = 0, 1
8
9  #生成两个正态分布的随机数
10 num_samples = 10000
11 X = np.random.normal(mu_1, sigma_1, num_samples)
12 Y = np.random.normal(mu_2, sigma_2, num_samples)
13
14 #生成服从二项分布的随机数，p是设定的参数
15 p = 0.5
16 epsilon = np.random.choice([0, 1], size=num_samples, p=[1 - p, p])
17
18 #计算出混合高斯分布值
19 Z = X + epsilon * Y
20
21 #将样本列出
22 samples = np.vstack((X, Y, epsilon)).T
23 print("Sample Values:")
24 print(" X          Y          eta")
25 print(samples[:])
26
27 #绘制频率分布曲线
28 sns.histplot(Z, bins=30, kde=True, color='green')
29
30 title_text = f'Gaussian Mixture Distribution\n( $\mu_1=\{mu_1\}$ ,
31               $\sigma_1^2=\{(\sigma_1)**2\}$ ,  $\mu_2=\{mu_2\}$ ,
32               $\sigma_2^2=\{(\sigma_2)**2\}$ ,  $p=\{p\}$ )'
33 plt.title(title_text)
34 plt.xlabel('Values')
35 plt.ylabel('Frequency')
36 plt.legend()
37 plt.show()
```

B 随机变量 U 频率直方图生成代码

```
1  import numpy as np
2  import matplotlib.pyplot as plt
3  import seaborn as sns
4
5  #定义两个正态分布的参数
6  mu_1, sigma_1 = -4, 1
7  mu_2, sigma_2 = 4, 1
8
9  #设定参数
10 p = 0.5
11 m = 10000
12 n = 2
13
14 #生成m组 每组n个的Z值
15 Z_values = []
16 for _ in range(m):
17     X = np.random.normal(mu_1, sigma_1, n)
18     Y = np.random.normal(mu_2, sigma_2, n)
19     epsilon = np.random.choice([0, 1], size=n, p=[1 - p, p])
20     Z = X + epsilon * Y
21     Z_values.extend(Z)
22
23 #计算U_i值
24 D_Z = sigma_1**2 + p * sigma_2**2 + mu_2**2*p * (1 - p)
25 E_Z = mu_1 + p * mu_2
26 U_values = [(np.sum(Z_i) - n * E_Z) / np.sqrt(n * D_Z) for Z_i in
27               np.array_split(Z_values, m)]
28
29 #绘制频率分布曲线
30 sns.histplot(U_values, bins=30, kde=True, color='green')
31
32 title_text = f'Frequency histogram of $U$\n($\mu_1=\{\mu_1\}$,
33               $\sigma_1^2=\{(\sigma_1)**2\}$, $\mu_2=\{\mu_2\}$,
34               $\sigma_2^2=\{(\sigma_2)**2\}$, $p=\{p\}$, $n=\{n\}$)'
35 plt.title(title_text)
36 plt.xlabel('$U$ Values')
37 plt.ylabel('Frequency')
38 plt.show()
```