



混合高斯分布的探究

姓 名：陈卓妍

学 号：523030910037

学 院：电子信息与电气工程学院

2024 年 12 月 7 日

摘要

本文是一份关于混合高斯分布的探究性学习报告。报告首先定义了混合高斯分布，即由两个或多个正态分布按照一定比例混合而成的分布。接着，通过生成 5000 个混合高斯分布的随机数，并绘制频率分布直方图，分析了不同参数对直方图“峰”形状的影响。研究发现， μ_1 的变化使两个峰左右平移， μ_2 的变化只会使一个峰左右平移； σ_1^2 的变化使两个峰变窄变宽， σ_2^2 的变化只会使一个峰变窄变宽； p 改变前后两项的权重，从而使两个“峰”的相对高度发生变化

报告还探讨了混合高斯分布的期望和方差，并绘制了随机变量 $U_i = \frac{1}{\sqrt{nD(Z)}} (\sum_{j=1}^n Z_{ij} - nE(Z))$ 的频率分布直方图（其中 Z_{ij} 代表计算机随机生成的第 i 组第 j 个混合高斯分布随机数），分析了不同 n 值对直方图“峰”的影响。最后，通过理论分析和中心极限定理，得出了 U 的分布随着 n 的增大越来越接近标准正态分布的结论。

报告最后总结了混合高斯分布的特性，并提供了生成混合高斯分布随机数和绘制频率分布直方图的 Python 代码。通过这项探究，作者深入理解了混合高斯分布的特性及其在实际应用中的意义。

关键词：混合高斯分布，频率分布直方图，正态分布

1 探究任务一

1.1 混合高斯分布的定义


随机变量 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$ ，则 $Z = X + \eta Y$ 服从的分布称为混合高斯分布。其中 $P(\eta = 0) = 1 - p$, $P(\eta = 1) = p$

1.2 混合高斯分布随机数

令 $\mu_1 = 0$, $\mu_2 = 10$, $\sigma_1 = 2$, $\sigma_2 = 2$, $p = 0.7$ ，则生成 5000 个混合高斯分布的随机数。


1.3 混合高斯分布频率直方图

根据 1.2 中的数据，画出频率分布直方图如下：




1.4 不同参数对频率直方图“峰”的影响

1.4.1 μ_1 对直方图的影响




通过观察图片，可以看到 μ_1 对直方图“峰”的形状没有明显影响，但是随着 μ_1 的增加，直方图的“峰”整体向 x 轴右侧平移，且移动距离与 μ_1 的增加值基本一致。

1.4.2 μ_2 对直方图的影响




通过观察图片，可以发现当 $|\mu_1 - \mu_2|$ 较小时，两个“峰”基本重叠，频率分布直方图上只显示单峰；当 $|\mu_1 - \mu_2|$ 较大时，频率分布直方图上出现两个“峰”，“峰顶”对应的值分别大致为 μ_1, μ_2 的值，且由随机变量 Y 产生的“峰”更高。

1.4.3 σ_1 对直方图的影响




通过观察图片可以发现，当 σ_1 较小时，频率分布直方图上呈现出两个“峰”，分别由随机变量 X 和 Y 决定；随着 σ_1 的增大，由随机变量 X 决定的“峰”逐渐变“矮宽”，并于随机变量 Y 决定的“峰”融合成为一个“峰”。

1.4.4 σ_2 对直方图的影响



通过观察图片可以发现，随着 σ_2 的增大，右侧由 Y 决定的“峰”逐渐变矮变宽，而左侧“峰”无明显变化。

1.4.5 p 对直方图的影响



通过观察以上图片，可以发现 p 影响两个“峰”之间的相对高度。随着 p 从 0 增大到 1，由 Y 决定的“峰”不断增高，由 X 决定的峰逐渐变矮。

1.5 理论分析

由正态分布的可加性可知 $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ ， X ， Y ， η 相互独立，则 Z 的分布函数为

$$\begin{aligned} F_Z(z) &= P(Z \leq z) = P(X + \eta Y \leq z) = P(X \leq z | \eta = 0)P(\eta = 0) + P(X + Y \leq z | \eta = 1)P(\eta = 1) \\ &= P(X \leq z)P(\eta = 0) + P(X + Y \leq z)P(\eta = 1) \\ &= (1-p) \int_{-\infty}^z \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}} dx + p \int_{-\infty}^z \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} e^{-\frac{(x-(\mu_1+\mu_2))^2}{2(\sigma_1^2 + \sigma_2^2)}} dx \end{aligned}$$

对 $F_Z(z)$ 求导得到密度函数：

$$f_Z(z) = (1-p) \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(z-\mu_1)^2}{2\sigma_1^2}} + p \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} e^{-\frac{(z-(\mu_1+\mu_2))^2}{2(\sigma_1^2 + \sigma_2^2)}}$$

由密度函数，可以得到以下结论：

1. μ_1 的变化使两个峰左右平移， μ_2 的变化只会使一个峰左右平移
2. σ_1^2 的变化使两个峰变窄变宽， σ_2^2 的变化只会使一个峰变窄变宽
3. p 改变前后两项的权重，从而使两个“峰”的高度发生变化

由密度函数得出的结论与前述结论相一致。

2 探究任务二

2.1 混合高斯分布的期望和方差


$$E(Z) = E(X + \eta Y) = E(X) + E(\eta)E(Y) = \mu_1 + p\mu_2$$

$$D(Z) = \sigma_1^2 + p\sigma_2^2 + p(1-p)\mu_2^2$$

2.2 随机变量 U 的频率分布直方图


$$U_i = \frac{1}{\sqrt{nD(Z)}} \left(\sum_{j=1}^n Z_{ij} - nE(Z) \right)$$







其中 Z_{ij} 代表计算机随机生成的第 i 组第 j 个随机数，取 $n=1000$ ， U 的频率分布直方图如下。












2.3 n 值对频率分布直方图“峰”的影响

2.3.1 $\mu_1 = 0, \mu_2 = 10$




















2.3.2 $\mu_1 = 0, \mu_2 = 50$




2.3.3 $\mu_1 = 0, \mu_2 = 100$



2.3.4 $\mu_1 = 0, \mu_2 = 1000$





通过分析以上 4 组图片，可以得出以下结论：

1. 当 μ_1, μ_2 比较接近时，只有当 n 很小（如等于 2）时才有双峰出现，否则均在频率分布直方图上表现为一个峰，且唯一的“峰”出现在 0 附近。
2. 当 μ_1, μ_2 差值较大时，若 n 值较小，图上可出现 $n+1$ 个明显分立的“峰”，但随着 n 值的增大，“峰”逐渐密集并汇聚在一起，难以辨别“峰”的个数，直至汇聚成一个“峰”，单峰出现在 0 附近。
3. 由于 p 取 0.7，当 n 较小时可以明显发现高度最高的“峰”偏向图的右侧，而不是对称分布。

2.4 理论分析

对于每一组，随机变量 Z_{ij} 独立同分布， $E(Z_{ij}) = E(Z) = \mu_1 + p\mu_2, D(Z_{ij}) = D(Z) = \sigma_1^2 + p\sigma_2^2 + p(1-p)\mu_2^2$ 。

由中心极限定理可知：

$$\lim_{n \rightarrow +\infty} P\left(\frac{1}{\sqrt{nD(Z)}}\left(\sum_{j=1}^n Z_{ij} - nE(Z)\right) \leq x\right) = \Phi(x)$$

故有

$$\lim_{n \rightarrow +\infty} P(U_i \leq x) = \Phi(x)$$

故当 n 逐渐增大时， U 越来越接近标准正态分布，与图片中的特征基本吻合。

3 感想

在完成这份关于混合高斯分布的探究性学习报告后，我深刻体会到了统计学在数据分析中的强大应用，以及对复杂分布进行建模的重要性。通过对混合高斯分布的深入研究，我不仅巩固了对正态分布的理解，还学会了如何通过参数调整来影响和控制分布的形状和特性。

实验过程中，我通过编程生成随机数并绘制频率分布直方图，这种实践操作让我更加直观地感受到了理论在实际中的应用。观察不同参数对直方图“峰”形状的影响，我学会了如何通过视觉化工具来分析和解释数据。

此外，通过理论分析和中心极限定理的应用，我进一步理解了样本量对分布特性的影响，以及在大量样本条件下，随机变量的分布趋向于正态分布的统计特性。这种理论联系实际的学习方式，让我对统计学的理解更加深刻。在编写 Python 代码的过程中，我也提升了自己的编程技能。

此外，我想在此感谢熊老师课堂上详细讲解了复杂的概念和理论，使我能够灵活地把所学知识运用到本次实验探究中，让我受益匪浅。在未来的学习和研究中，我将继续运用在课堂上学到的知识和技能，不断探索和前进。

总的来说，这次混合高斯分布的探究不仅增强了我的理论知识，也提高了我的实践能力。我期待将

这些新学到的技能应用到更广泛的领域中，解决更多实际问题。

4 附录

4.1 探究任务一生成代码

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# 设定参数
mu1 = 0
mu2 = 10 # 高斯分布的均值
sigma1 = 2
sigma2 = 2 # 高斯分布的标准差
p = 0.7 # 混合比例
# 生成100个符合N(0, 1)的随机变量
x = np.random.normal(mu1, sigma1, 5000)
y = np.random.normal(mu2, sigma2, 5000)
# 定义eta的值和它们的概率
values = [0, 1]
probabilities = [1-p, p]
# 生成随机变量eta
a = np.random.choice(values, size = 5000, p=probabilities)
z = x + a*y
# 画出频率分布直方图
sns.histplot(z, bins=30, kde=True, color='black')
plt.title(f'Mixed Gaussian Distribution\n ( $\mu_1 = \{mu1\}$ ,  $\sigma_1 = \{sigma1\}$ ,  $\mu_2 = \{mu2\}$ ,  $\sigma_2 = \{sigma2\}$ ,  

 $p = \{p\}$ ')
plt.xlabel('Value')
plt.ylabel('Frequency')
plt.savefig(f'D:/概率论与数理统计/大作业/Task1/mu1 = {mu1}_sigma1 = {sigma1}_mu2 = {mu2}_sigma2 = {sigma2}_p = {p}.jpg')
plt.show()
```

4.2 探究任务二生成代码

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# 设定参数
mu1, mu2 = 0, 10 # 高斯分布的均值
sigma1, sigma2 = 2, 2 # 高斯分布的标准差
p = 0.7 # 混合比例
```

```

n = 1000
# 生成100个符合 $N(0, 1)$ 的随机变量
for n in [2,3,4,5,10,20,50,100,5000]:
    for mu2 in [10,50,100,1000]:
        values = [0, 1]
        probabilities = [1-p, p]
        EZ = mu1 * (1 - p) + p*(mu1 + mu2)
        DZ = (sigma1**2) + p * (sigma2**2) + p * (1-p) * (mu2)**2
        U = []
        for i in range(1000):
            x = np.random.normal(mu1, sigma1, n)
            y = np.random.normal(mu2, sigma2, n)
            a = np.random.choice(values, size = n, p=probabilities)
            z = x + a*y
            U1 = (z.sum() - n * EZ) / (n * DZ)**0.5
            U.append(U1)
        U = np.array(U)
        # 画出频率分布直方图
        sns.histplot(U, bins=30, kde=True, color='black')
        #plt.hist(U, bins=50, density=True, alpha=0.6)
        plt.title(f'Mixed Gaussian Distribution\n ( $\mu_1 = \{mu1\}$ ,  $\sigma_1 = \{sigma1\}$ ,  $\mu_2 = \{mu2\}$ ,  $\sigma_2 = \{sigma2\}$ ,  $p = \{p\}$ ,  $n = \{n\}$ )')
        plt.xlabel('U Value')
        plt.ylabel('Frequency')
        plt.savefig(f'D:/概率论与数理统计/大作业/Task1/mu1 = {mu1}_sigma1 = {sigma1}_mu2 = {mu2}_sigma2 = {sigma2}_p = {p}_n = {n}.jpg')
        plt.show()

```